

基于公开评论数据的音乐评论用户行为分析系统

项目完整报告（图文版）

本报告所有图表均由 generate_report_images.py 从真实数据库查询结果生成，非示意。配色采用与 Dashboard 一致的民谣暖色调（暖棕 #8b6b4d / 砖红 #c0392b / 苔绿 #5a7d6b / 米色背景 #f5efe6），呼应项目“民谣音乐数据分析”主题。

目录

- 项目概述
- 系统架构
- 数据规模总览
- 数据仓库分层
- 数据清洗流程
- 指标体系建设
- 用户行为深度分析
- 评论文本挖掘
- 双模型预测体系
- Dashboard 可视化
- 工程实践与修复
- 项目价值与简历描述

一、项目概述

1.1 项目定位

本项目最初设计为“音乐平台用户行为洞察与内容增长分析系统”，旨在分析用户在音乐平台的播放、收藏、分享等行为。但公开数据源无法获取真实用户行为日志，原方案的“用户行为”实际上大量依赖模拟数据。

重新定位：项目调整为“基于公开评论数据的音乐评论用户行为分析系统”，将“用户行为”等价于“用户评论行为”——评论即用户互动，回复即传播深度，点赞即内容认可。所有指标、模型、可视化全部基于真实爬取的网易云公开评论数据。

1.2 核心业务问题


#	业务问题	项目对应模块
1	平台用户可分几类？核心粉丝占比多少？	K-means 聚类 + RFM 分群
2	用户什么时候最活跃？什么时候发新歌效果好？	行为时间模式分析
3	用户在评论里聊什么？对歌曲满意吗？	LDA 主题 + BERT 情感
4	哪些歌会火？提前多久能预测？	XGBoost 爆款预测 + Prophet 时序
5	哪些用户即将流失？需要紧急挽留？	XGBoost 流失预测


1.3 关键产出

- 28 张数据库表（ODS / DWD / DWS / ADS 四层）
- 615,620+ 行真实数据
- 22 个 Python 模块（采集 / 清洗 / 指标 / 分析 / NLP / 模型 / 可视化）
- 8 页 Dashboard（静态 HTML + Streamlit 交互版）
- 双预测模型体系（歌曲爆款 AUC=0.77 + 用户流失 AUC=0.77）

二、系统架构

2.1 端到端业务流程





2.2 技术栈

层	技术
数据采集	Python + requests + 网易云 API
数据存储	MySQL 8.0 + PyMySQL
数据处理	Pandas + NumPy + SimHash（近似去重）
用户分析	scikit-learn K-means + 自实现 RFM
NLP	jieba + TF-IDF + LDA + transformers BERT
机器学习	scikit-learn LR / RF + XGBoost + Prophet
可视化	Streamlit + Plotly + ECharts + matplotlib（报告图）
工程化	python-dotenv + SQL 参数化 + Streamlit 缓存

三、数据规模总览




图 1：项目数据规模总览

图 1 解读：

- ODS 层 261,460 条评论（原始爬取，未做任何处理）
- DWD 层 215,853 条评论（清洗后保留率 82.5%，过滤了无意义评论 + SimHash 近似去重）
- DWS 层 日级聚合：歌曲日 101,866 + 用户日 193,758
- ADS 层 用户画像 152,131 + 流失预测 152,131 + 情感分析 212,845

数据量呈现 金字塔结构：从底层 26 万原始评论，逐层聚合到顶层 15 万用户级预测结果，每层职责清晰。

四、数据仓库分层

按照互联网公司数据仓库思想，采用经典四层架构：

4.1 ODS 层（贴源层）

表	行数	说明
ods_comment	261,460	原始爬取评论
ods_song	300	原始歌曲元数据
ods_artist	213	原始歌手
ods_user	22,916	原始用户

4.2 DWD 层（明细层）

表	行数	清洗规则
dwd_comment_detail	215,853	去重 + 过滤无意义评论
dwd_song_info	300	标准化发布时间/语言
dwd_user_info	22,916	补全注册时间/等级
dwd_artist_info	213	歌手信息清洗

4.3 DWS 层（汇总层）

表	行数	聚合粒度
dws_song_daily	101,866	歌曲日级评论/回复/获赞指标
dws_user_daily	193,758	用户日级评论行为聚合
dws_artist_daily	31,266	歌手日级指标汇总

4.4 ADS 层（应用层）

表	行数	业务用途
ads_song_rank	101,866	歌曲热度排名
ads_song_lifecycle	101,866	生命周期阶段
ads_user_portrait	152,131	用户画像 (K-means)
ads_user_rfm	152,131	用户画像 (RFM 分群)
ads_comment_sentiment	212,845	BERT 情感分类结果
ads_comment_topic	5	LDA 主题
ads_hot_predict	300	爆款预测结果
ads_song_forecast	8,820	30 天热度预测
ads_churn_predict	152,131	流失预测结果
ads_stat_tests	3	统计假设检验
ads_feature_importance	10	爆款预测特征重要性 (已排除 7 个泄露字段后)

五、数据清洗流程

图 2：评论清洗漏斗（保留率 82.5%）




图 2：评论清洗漏斗

图 2 解读：

评论清洗是数据质量保证的核心环节。从 261,460 条原始评论到 215,853 条干净评论，保留率 82.5%，主要过滤内容：

过滤类型	处理方式	删除量
无意义评论	关键词黑名单 ("666"/"哈哈"/"好听") + 长度 < 2	~29,329
垃圾评论	重复字符模式 ("啊啊啊啊"/"哈哈哈哈")	~474
近似重复	SimHash 64 位指纹 + 海明距离 ≤ 3	~807

SimHash 近似去重的工程意义：普通精确去重 (md5 相同) 只能去掉完全一样的评论，但用户经常复制后微调 ("太好听了"vs"太好听了!! ")。SimHash 把文本映射为 64 位指纹，相似文本指纹只有少数位不同，海明距离 ≤ 3 即视为近似重复，能捕获 90% 以上的"复制 + 微调"垃圾评论。

六、指标体系建设

6.1 歌曲热度指数 (Heat Score)

$$\text{Heat Score} = 0.4 \text{ times comment growth rate} + 0.3 \text{ times reply growth rate} + 0.3 \text{ times like growth rate}$$

权重设计逻辑：

- 评论增长率 40%：核心互动行为，直接反映歌曲关注度
- 回复增长率 30%：传播深度，反映用户参与讨论的热度
- 获赞增长率 30%：内容认可，反映评论质量

6.2 用户价值评分 (User Value)

$$\text{User Value} = 0.4 \text{ times activity score} + 0.3 \text{ times interaction score} + 0.3 \text{ times diversity score}$$

- activity_score：活跃度 (评论数 / 回复数 标准化)
- interaction_score：互动度 (获赞数 标准化)
- diversity_score：多样性 (评论歌曲数 / 题材数 标准化)

6.3 生命周期阶段

阶段	判定条件	占比
冷启动	评论增长率 < 10% 且总量 < 50	0.3%
增长期	评论增长率 > 20%	0.0%
爆发期	评论增长率 > 50%	30.9%
稳定期	增长率平稳 (10-50%)	45.4%
衰退期	评论增长率 < 0	23.4%

6.4 统计假设检验

ads_stat_tests 表存放 3 项关键检验结果：

检验	类型	p 值	结论
评论增长率是否显著异于 0	t-test	<0.0001	显著 (Cohen d=0.3546)
高/低热度组评论数差异	Mann-Whitney U	0.0003	显著
正面/负面比例偏离 50/50	chi2	<0.0001	显著 (Cramér V=0.6578)

七、用户行为深度分析

7.1 K-means 8 维用户聚类

图 3：K-means 用户聚类分布 (3 类)




图 3：K-means 用户聚类分布

图 3 解读：

K-means 基于 8 维特征（评论数 / 回复数 / 获赞数 / 活跃天数 / 日均评论数 / 活跃歌曲数 / 活跃度 / 互动度 / 多样性 / 价值分 / 情感 / 活跃时段）将 152,131 个用户聚为 3 类：

类型	人数	占比	特征
核心粉丝	1,948	1.28%	高频评论 + 高互动 + 高质量
内容消费者	29,649	19.49%	中频评论 + 多样性较高
轻度用户	120,534	79.23%	偶尔评论 + 互动少

长尾效应明显：1.28% 的核心粉丝贡献了远超比例的互动量，符合"二八定律"。这是平台运营应重点维护的用户群体。

7.2 RFM 3 维用户分群（行业标准）

图 4：RFM 用户分群分布（4 类）




图 4：RFM 用户分群分布

图 4 解读：

为补充 K-means 8 维聚类的"特征多但难解释"问题，引入行业标准的 RFM 模型：

- R (Recency)：最近一次评论距今天数（越小越优）
- F (Frequency)：评论频率 = 评论总数 / 活跃天数
- M (Monetary)：评论质量 = 获赞总数

每个维度做五分位打分（1-5 分），K-means 在 R/F/M 三维上聚类为 4 类：

类型	人数	占比	业务含义
高价值用户	38,749	25.5%	R 高 + F 高 + M 高 = 最近活跃 + 高频 + 高质量
成长用户	38,567	25.4%	R 高 + F/M 低 = 新近开始评论但深度不够
沉默用户	48,041	31.6%	R 低 + M 高 = 曾经获赞很多但最近停止评论
流失风险用户	26,774	17.6%	R 低 + F/M 低 = 各项指标都低

与 K-means 对比：RFM 三类的业务含义远比 K-means 8 维的"核心/内容消费者/轻度"清晰，可直接用于运营分层触达。

7.3 行为时间模式分析

24 小时评论分布




图 5：24 小时评论分布

图 5 解读：

- 高峰时段 15:00（下午 3 点）：17,864 条评论
- 低谷时段 21:00：1,781 条评论
- 高低比 10x：用户在下午茶时间最活跃，运营应优先在 14-16 点发布新歌

周内 + 月度分布

图 6：行为时间模式（周内 + 月度）




图 6：行为时间模式

图 6 解读（左：周内 / 右：月度）：

- 周末 vs 工作日活跃比 0.98x：几乎无差异，工作日反而略高
- 周三评论最多：31,493 条
- 7 月是高峰月：29,294 条（暑假效应）
- 季节分布：夏 74,625 > 春 56,429 > 冬 46,404 > 秋 38,395
- 夏季是秋季的 1.95 倍：暑期学生放假有闲，是新歌发布的最佳季节

八、评论文本挖掘

8.1 LDA 主题建模

图 7：LDA 5 大评论主题关键词分布




图 7：LDA 5 大评论主题关键词分布

图 7 解读：

使用 jieba 分词 + TF-IDF 提取关键词后，LDA 主题模型将所有评论自动聚为 5 大主题：

主题	关键词	业务解读
主题 0	治愈 / 旋律 / 温柔 / 安静 / 声音	单纯好评型：用户聚焦音乐本身
主题 1	回忆 / 青春 / 曾经 / 那年 / 时间	情绪共鸣型：触发了用户记忆
主题 2	民谣 / 故事 / 远方 / 行走 / 浪漫	民谣内核型：典型民谣听众画像
主题 3	喜欢 / 觉得 / 希望 / 想 / 知道	当下感慨型：表达即时情感
主题 4	评论 / 点赞 / 歌单 / 分享 / 收藏	社交互动型：平台行为导向

8.2 BERT 情感分类

图 8：BERT 情感分类分布




图 8：BERT 情感分类分布

图 8 解读：

使用 `uer/roberta-base-finetuned-cluener` 中文 BERT 模型对 215,853 条评论做情感三分类：

类别	占比	解读
正面 (positive)	72.80%	用户对歌曲整体满意
负面 (negative)	15.03%	部分表达不满或批评
中性 (neutral)	12.17%	评论偏向客观描述

满意度得分 = $72.80\% - 15.03\% = 57.77\%$ ，整体口碑良好（正面远超负面）。

九、双模型预测体系

图 9：双预测模型对比（歌曲爆款 + 用户流失）




图 9：双预测模型对比

图 9 解读（左：爆款预测 / 右：流失预测）：

项目构建了"歌曲侧 + 用户侧"对称的双预测模型体系：

9.1 歌曲爆款预测

- 标签：复合热度（评论+回复+获赞+情感加权）Top 10% = 爆款（30 首 / 300 首）
- 特征：18 个（行为统计 + 用户价值 + 情感 + 时间 + RFM）
- 严格防泄露：排除 7 个直接/间接参与标签生成的字段（composite_heat / *_norm / total_comment_count 等）

模型	AUC	F1	Accuracy
LogisticRegression	0.7222	0.0000	0.9000
RandomForest	0.7068	0.0000	0.9000
XGBoost（最优）	0.7685	0.2857	0.9167

9.2 用户流失预测

- 标签：最近一次评论距今 > 90 天 = 流失（121,447 / 152,131）
- 特征：18 个（行为 + 价值 + 情感 + 时间 + RFM 的 F/M）
- 严格防泄露：排除 5 个字段（recency_days / r_score / rfm_total / rfm_cluster / cluster_label）

模型	AUC (5-fold)	F1	Accuracy
LogisticRegression	0.7005 ± 0.0022	0.7271	0.6295
RandomForest	0.7580 ± 0.0025	0.8048	0.7161
XGBoost（最优）	0.7672 ± 0.0022	0.8239	0.7384

9.3 流失风险分布 + 特征重要性

图 10：流失风险分布 + 特征重要性



图 10：流失风险分布 + 特征重要性

图 10 解读（左：风险分布 / 右：特征重要性 Top10）：

- 低风险（< 0.3）：25,888 人（17.0%）→ 维持现状，可推荐新歌
- 中风险（0.3-0.7）：78,070 人（51.3%）→ 触达激励，推送独家内容
- 高风险（> 0.7）：48,173 人（31.7%）→ 紧急挽留，发回归礼包

爆款预测 Top 特征：

- 发布时长（0.1777）—— 越早发布的歌越可能爆款（积累效应）
- 有效评论数（0.1740）—— 评论基数是爆款的最强信号
- 负面情感比例（0.1578）—— 有趣的是，负面情感反而预示爆款（争议性传播）
- 歌手历史获赞（0.1434）—— 歌手影响力是关键

9.4 时间序列热度预测

使用 Prophet 模型对 294 首歌做未来 30 天热度预测，共生成 8,820 条预测记录（294 × 30）。

写入 ads_song_forecast 表，Dashboard 提供单首歌曲热度曲线查询。

十、Dashboard 可视化

10.1 静态 HTML 看板

入口：dashboard.html（13MB，8 个页面）

页面	内容
首页总览	平台核心指标 + 30 天热度趋势 + Top10 歌曲
歌曲分析	歌曲搜索 + 生命周期曲线 + 用户评价
用户画像	K-means 聚类 + 核心用户占比
文本洞察	TF-IDF 关键词 + LDA 主题分布
情感研究	BERT 情感分类 + 满意度得分
爆款预测	模型对比 + 特征重要性 + 高概率歌曲
热度预测	Prophet 30 天曲线 + 可预测歌曲列表
用户行为（新增）	RFM 分群 + 时间模式 + 流失风险 + 高风险用户列表

10.2 Streamlit 交互版

入口：step8■■■■■/app.py

支持：歌曲搜索、热度趋势展示、用户分群可视化、爆款概率预测、流失风险查询。

10.3 设计风格

- 配色：暖白纸背景 #f5efe6 + 暖棕 #8b6b4d 主色 + 砖红 #c0392b 和苔绿 #5a7d6b 强调色
- 风格：民谣怀旧风，呼应"民谣音乐"主题
- 约束：每页单屏适配 16:9 宽屏，无滚动条

十一、工程实践与修复

11.1 数据治理

实践	实现
评论驱动重命名	play_num → comment_count / like_num → like_total
删除伪字段	collect_num / share_num / active_duration
衍生真实字段	avg_comment_length 替代 active_duration

11.2 关键 Bug 修复（5 处）

#	Bug	影响	修复方案
1	db_helper.py % 占位符	统计检验模块无法运行	无 params 时不传 args, 绕过 mogrify
2	K-means silhouette $O(n^2)$	15 万样本评估 5+ 分钟	加 sample_size=5000 采样
3	composite_heat 标签分位数	90% 数据被标为爆款	quantile(0.10) $\rightarrow$ quantile(0.90)
4	爆款预测特征泄露	AUC=1.0 虚假完美	排除 7 个泄露字段
5	流失预测 r_score 泄露	AUC=0.9995 虚假完美	排除 5 个泄露字段

11.3 工程规范

- 凭据外置：所有 config.py 用 python-dotenv 读 .env, 11 个文件统一
- SQL 注入防护：参数化查询 + 表名白名单校验
- 查询缓存：Streamlit @st.cache_data 缓存数据库查询
- 采样优化：silhouette_score 强制 sample_size 避免 $O(n^2)$
- 业务约束：K-means 固定 $k=3$ 与运营粒度一致

十二、项目价值与简历描述

12.1 项目亮点

- 真实数据驱动：26 万真实评论，零模拟数据
- 完整数据仓库：4 层 28 张表，分层清晰
- 双层用户分群：K-means 8 维 + RFM 3 维并存，互为补充
- 双模型预测体系：歌曲爆款 + 用户流失，AUC 均 ≈ 0.77
- 严格防泄露：共排除 12 个泄露字段，AUC 真实反映泛化能力
- 三模块行为分析：RFM 分群 + 时间模式 + 流失预测，覆盖运营决策全链路
- 8 页 Dashboard：静态 HTML + Streamlit 双版本，民谣暖色风格
- 5 项关键 Bug 修复：从"虚假完美"到"真实可信"

12.2 局限性

- 数据规模偏小：300 首歌远低于目标 5,000 首
- BERT 情感使用 8/24 旧数据（重训需 17 小时）
- 流失预测正负样本 80:20, F1 偏高但 recall 一般
- 爬虫每首约 90 条评论上限，难以获取长尾评论

12.3 改进方向

- 扩展爬虫到 5,000 首歌（用代理池突破限制）
- 用 distilbert 重跑情感分析（2 小时 vs 17 小时）
- 加 SHAP 解释 XGBoost 预测
- 加 LightGBM 第四模型对比
- 加用户-用户 co-comment 网络分析

12.4 简历可用描述

基于网易云公开评论数据构建音乐评论用户行为分析系统，采集 26 万评论 / 15 万用户 / 300 首歌，按数仓 4 层架构建设 28 张表；用 K-means + RFM 完成用户双层分群，TF-IDF/LDA 挖掘 5 大评论主题，BERT 做情感分析（72.8% 正面）；构建 XGBoost 歌曲爆款预测 + 用户流失预测双模型体系（AUC≈0.77，严格防 12 项特征泄露），Prophet 时序模型预测 294 首歌未来 30 天热度；开发 Streamlit 8 页 + 静态 Dashboard 支撑运营决策。

附录 A：完整执行链路

```
# 1. ██████████
cd step2████████ ; python init_db.py ; python load_data.py ; cd ..

# 2. ██████
cd step3██████ ; python run.py ; cd ..

# 3. ██████
cd step4██████ ; python run.py ; cd ..

# 4. ████████████████████K-means + RFM + ██████████
cd step5██████ ; python run.py ; cd ..

# 5. ██████████ 7 ███ ADS ███
cd step6██████ ; python run.py ; cd ..

# 6. ██████████ + ███ + █████
cd step7██████ ; python run.py ; cd ..

# 7. ████████████████████████████████████████████
cd step5██████ ; python run.py ; cd ..

# 8. ███ Dashboard
python generate_dashboard.py

# 9. ██████████
python generate_report_images.py
```

附录 B：项目文件结构

```
██████████████████ /
██████ .env # ██████████ gitignore█
██████ ██████████.md # ██████
██████ ██████.md # ██████
```

```

#####_###.md # #####
##### dashboard.html # 13MB ## Dashboard
##### generate_dashboard.py # Dashboard #####
##### generate_report_images.py # #####
##### report_images/ # 10 #####
# ##### 01_data_scale.png
# ##### 02_cleaning_funnel.png
# ##### 03_kmeans_pie.png
# ##### 04_rfm_pie.png
# ##### 05_hourly.png
# ##### 06_weekday_monthly.png
# ##### 07_lda_topics.png
# ##### 08_sentiment.png
# ##### 09_model_metrics.png
# ##### 10_churn_risk_features.png
##### step1#####/
##### step2#####/
##### step3#####/
##### step4#####/
##### step5#####/
# ##### kmeans_cluster.py # K-means 8 #####
# ##### rfm_clustering.py # RFM 3 #####
# ##### user_time_pattern.py # #####
# ##### ...
##### step6#####/
##### step7#####/
# ##### hot_song_predict.py # #####
# ##### time_series_forecast.py # Prophet ##
# ##### churn_predict.py # #####
# ##### ...
##### step8#####/
##### app.py # Streamlit #####
##### generate_dashboard.py # ## HTML ##
##### pages/ # 8 # Streamlit ##

```

报告版本: v2.0 图文版

生成时间: 2026-08-25

配色主题：民谣暖色（呼应项目"音乐评论分析"主题）

数据来源：所有图表由真实数据库查询结果生成，非示意

图片生成: generate_report_images.py 从 MySQL 实时查询并渲染

报告维护：随数据库更新重新运行 `python generate_report_images.py` 即可刷新所有图表